




실선: 서비스 통신 · 주황 점선: 배포 경로 · CodeBuild는 Core / AI 이미지만 교체 · 운영 환경값·Compose는 별도 관리
기준 배포 확인 기록 + 저장소 설정 기준 · 작성 시 AWS 세션 만료로 실시간 상태 재조회 안 됨 · 단일 EC2 / 중단 가능 · OAuth·백업 복구·부하 검증 완료로 뜻하지 않음 · 비밀값 미표기

Vercel + AWS 배포 구성

Vercel
화면 제공과 같은 주소의 API 진입점

비공개 EC2
업무·AI·검색 엔진·큐를 Docker Compose로 실행

RDS MySQL
원본 데이터와 계정·업무 상태 저장

사용자 요청: Vercel에서 비공개 Core까지

01 브라우저와 Vercel

govbiz.vercel.app에서 화면 제공
브라우저는 같은 주소의 /api/* 호출
React·TypeScript 정적 파일 배포

02 Vercel 서버 미들웨어

프록시 인증 헤더를 서버에서 추가
쿠키·메서드·본문을 AWS로 전달
AI 실행은 Core·FastAPI가 담당

03 CloudFront VPC origin

HTTPS 요청을 VPC origin으로 연결
프라이빗 EC2의 Nginx :80에 진입
API 캐시는 비활성화

04 Nginx와 Core API

Nginx가 프록시 요청을 확인
Core :8080에서 인증과 업무 처리
필요한 AI 요청은 FastAPI :8000 호출

실행 환경과 데이터 저장 위치

EC2 1대: Docker Compose

Nginx·Core·FastAPI를 함께 실행
Elasticsearch·Qdrant·Redis·RabbitMQ 포함
내부 서비스는 컨테이너 네트워크로 통신

RDS MySQL 8.4: 원본 DB

공고 원본과 계정·업무 상태 저장
EC2 밖의 프라이빗 RDS 사용
Core는 TLS로 데이터베이스에 연결

EBS 40 GiB: 영속 데이터

검색 색인·벡터·복원 상태·큐 데이터
EC2의 영속 볼륨에 보관
영속 볼륨과 백업은 별도 관리

저장소별 역할 분리

Elasticsearch: 키워드 검색
Qdrant: 의미·근거 검색
Redis: 결과 복원 / RabbitMQ: 작업 전달

서비스 진입·외부 호출·인증 경계

외부 진입: CloudFront

VPC origin으로 Nginx에 연결
EC2에 공인 IP를 부여하지 않음
진입 요청은 NAT를 통과하지 않음

외부 호출: NAT·IGW

Core는 공고 API, AI는 OpenAI 호출
EC2에서 NAT Gateway·IGW를 거쳐 송신
공개 인터넷 통신은 HTTPS 사용

회원 인증과 프록시 검증

서버 전용 헤더로 프록시 경로 확인
회원 세션·권한은 Core에서 별도 검사
API 응답의 CDN 캐시는 비활성화

비밀값과 내부 서비스

OpenAI·DB 비밀값은 EC2 서버에 보관
Core·AI·검색 엔진·큐 포트는 비공개
컨테이너 내부 TLS·상호 인증은 미적용

백엔드 자동 배포: CodeBuild·ECR·SSM

프론트는 GitHub 연동 Vercel 배포, GitHub Actions는 테스트·빌드 CI를 담당합니다.

01 main 변경과 검증

배포 저장소 main의 push로 시작
CodeConnections로 소스 연결
CodeBuild가 Core·AI·통합 테스트 실행

02 ECR 이미지 게시

검증을 통과한 Core·AI 이미지만 게시
commit 태그와 sha256 digest로 고정
이전 이미지 정보를 복구용으로 보관

03 SSM 배포 명령

SSM이 기존 EC2에 배포 명령 전달
환경 파일의 두 이미지 값만 교체
Compose·비밀값 전체를 덮어쓰지 않음

04 컨테이너 교체·확인

AI healthy 확인 후 Core 교체
Nginx reload 후 건강 상태 확인
실패 시 이전 이미지 복구를 시도

배포 기록과 운영상의 제약

배포 기록에 포함된 확인

Vercel 화면과 CloudFront VPC origin
EC2·Compose 기동과 RDS TLS 연결
운영 데모 입력 확인 기록

현재 상태는 별도 확인

2026-09-16 정리한 기록 기반 구성도
현재 자원·webhook·최근 배포는 미재조회
실시간 운영 상태를 보증하는 자료는 아님

단일 EC2의 가용성

호스트 장애가 여러 구성 요소에 영향
컨테이너 교체 중 일시 중단 가능
다중 서버·무중단 배포 구성은 아님

복구와 후속 검증

이미지 복구와 DB migration 복구는 구분
백업 복구 시험·부하·보안 검증 필요
외부 API 장애·호출 비용도 별도 관리

화면·업무·AI의 책임을 나눈 3개 서비스

브라우저는 Core API만 호출하고, 외부 API 키는 서버에서 관리합니다.

01 FRONTEND

React · TypeScript

MVVM Hook과 Redux Toolkit
화면 표시·요청 상태 관리
Zod로 HTTP 응답 검증

02 CORE API

Spring Boot · Kotlin

JDK 21 기반 업무 흐름
인증·공고·신청 준비 관리
MyBatis와 MySQL 영속화

03 AI SERVICE

FastAPI · OpenAI

Pydantic 기반 응답 계약
조건 해석·랭킹·근거 답변
Qdrant 의미·근거 검색

MySQL 원본 / Elasticsearch·Qdrant 검색 / Redis 임시 복원 / RabbitMQ 작업 전달

Frontend: 화면과 요청 상태를 분리

MVVM · Custom Hook

View는 렌더링과 이벤트 연결에 집중
ViewModel은 화면 상태·동작을 제공
UseCase와 Repository가 HTTP 경계를 담당

Awilix · 객체 연결

앱에서 UseCase와 Repository를 조립
협력 객체의 관리와 화면 상태 관리를 분리
주요 의존 방향은 Presentation → Domain ← Data

Redux Toolkit · 단방향 상태

Action과 Reducer로 상태 변경을 추적
채팅 상태는 화면 이동 중에도 유지
DOM 참조·포커스는 Hook 로컬에 보관

요청 수명 · 응답 검증

요청 ID로 늦게 도착한 결과를 차단
AbortController·타이머는 별도 레지스트리
Zod로 잘못된 API 응답의 유입을 차단

새 데이터는 수집·색인 검증 후 공개

MySQL을 기준으로, 검증에 실패한 제공처의 기존 공개 데이터를 보존합니다.

01 전체 수집

누락과 중간 실패 검사

제공처 API의 모든 페이지 수집
총건수·응답 완전성 검증
식별자는 제공처 + 원본 ID

02 두 색인 준비

외부 호출은 트랜잭션 밖

Elasticsearch와 Qdrant 준비
본문 해시로 불변 버전 관리
기존 성공 버전은 재사용

03 MySQL 공개

현재 세대만 반영

짧은 DB 트랜잭션으로 공개
제공처별 UPSERT·비활성화
실패 시 다른 제공처는 유지

하이브리드 검색: 키워드와 의미를 함께

MySQL의 현재 공개 버전만 후보로 허용

Elasticsearch의 한국어 Nori-BM25와 Qdrant 의미 검색을 결합합니다.
AI는 관련도와 자격을 따로 검토합니다. 자격 미확인은 관련도 감점이 아닙니다.

20+20

키워드 후보 + 의미 후보
Elasticsearch + Qdrant

20

동일 가중치 RRF 결합
AI 랭킹에 넘길 최대 후보

5

최종 추천 최대 건수
부적합은 제외·미확인은 표시

AI 답변은 구조와 근거를 함께 검증

조건 해석·랭킹·근거 답변을 역할별로 실행합니다.

FastAPI의 Service가 Agent를 호출하고
OpenAI 결과를 타입·ID·인용으로 검증합니다.

상세 질문은 공식 HTML을 청크로 나눈 뒤
Qdrant에서 근거를 최대 5개 검색합니다.
충분한 근거가 없으면 답변을 보류합니다.

상세 Q&A: 기업마당 공식 HTML

같은 공고 ID·공식 HTTPS·본문을 검사
검색된 청크만 인용하고 Core가 재검증

공식 첨부 분석은 별도 경로

PDF·HWP·HWPX 양식을 수집·파싱
신청 문항 추출·중복 수혜 검토에 활용

Redis: 로그인해도 검색 결과를 이어서

첫 검색의 가속 캐시가 아니라, 검색 당시 결과를 30분 보관하는 저장소입니다.

01 비회원 검색

결과·조건 스냅샷 저장

최종 추천이 3~5건일 때 저장
화면에는 2건과 임시 토큰
0~2건은 Redis를 쓰지 않음

02 로그인·소유권 확인

Lua로 원자적 계정 연결

회원 세션을 별도로 확인
최초 복원 계정에 소유권 부여
다른 계정의 복원은 거부

03 전체 결과 복원

모델 재호출 없이 조회

전체 추천과 검색 조건 복원
조회해도 30분 TTL은 고정
공고·점수는 검색 당시 기준

비동기 작업: RabbitMQ로 접수·실행 분리

MySQL Outbox에 작업 저장
작업 ID만 RabbitMQ로 전달
Core 내부 소비자가 실행
결과 저장 후 ACK

중복 메시지는 DB 선점으로 방어
결과 불명은 UNKNOWN으로 기록
무작정 자동 재호출하지 않음

정기 리포트
생성·발송

중복 지원
수혜 검토

공식 신청
문서 분석

카카오 탈퇴
연결 해제

AI 생성과 SMTP 발송은 서로 다른 큐
외부 응답 대기를 예약 스레드에서 분리

요청 당시 입력을 고정하고 근거를 분석
202 접수 후 상태·저장된 결과 조회

공식 첨부 수집·문항 추출을 작업으로 관리
공고별 사전분석은 별도 Outbox 경로

탈퇴와 작업 저장을 같은 트랜잭션으로 처리
연결 해제 확인 전 같은 identity 재가입 차단

검색 및 RAG 평가: 테스트 계획과 판정 범위

2026.09.06~13 실행 기록 기준 · 후보 검색·최종 추천·근거 답변·지연을 각각 측정합니다

평가 단계	입력과 표본	확인 지표
후보 검색	한국어 표현 48문항 / Nori 비교 300문항	목표 공고 Hit@K · MRR@20
최종 추천	양성 2문항 / 무정답 4문항	Recall@5 · MRR@5 · 오추천
근거 답변	가상 6문항 + 공식 HTML 6문항	기대 상태 · 인용 경로 · 조건 보존
지연·실패	반복 검색 2회 / 처리 방식별 6회	성공/시도 · 지연 중앙값

Hit@K: 상위 K개 내 목표 공고 존재 | Recall@K: 관련 공고 회수 비율 | MRR@K: 첫 관련 공고 순위의 역수 평균

입력·설정 고정 → 전후 실행 → 실패 포함 보존 → 지표 재계산 → 사례 검토
 개발 진단·소표본 결과이며 공통 사전 합격선은 없었습니다. 사람 검수·독립 검증셋은 후속 과제입니다.

한국어 검색: 표현 변화에 따른 누락 감소

키워드 후보 단계의 목표 공고 찾기 실험이며, 두 평가의 표본은 서로 다릅니다

Nori 도입

목표 공고 16개 × 3가지 표현 = 48문항

Hit@1

Python exact-token		52.08%
Nori BM25		95.83%

Hit@20 39/48 → 48/48

문장형 Hit@20 8/16 → 16/16

Nori v1 → v2

기존 개발 진단 300문항

지표	v1	v2
Hit@1	258/300	268/300
Hit@20	295/300	299/300

순위 하락 9문항 · 누락 Q041 잔존
형태소 분해·사용자 사전·동의어 조정

후보 20개 유지: Hit@15 298/300 → Hit@20 299/300 · Q044 목표 공고 16위
300문항은 이미 개발에 사용했습니다. 후보 15개일 때의 지연·비용은 별도로 실측하지 않았습니다.

RRF 결합 검색: 후보와 최종 순위 개선 관측

16문항 중 양성 2개·무정답 4개 평가 / 미확정 10개 제외 / AI 참조 라벨

양성 2문항의 평균

지표	의미 검색	RRF 결합
후보 Recall@20	0.50	0.75
최종 Recall@5	0.50	0.75
최종 MRR@5	0.50	1.00

Recall은 질문별 회수 비율을 평균한 값입니다.

Q02: 누락 회복과 남은 실패

부산 AX 에이지테크
후보 3위 → 최종 1위

산업융합 규제샌드박스
 사업화 공고는 누락 유지

무정답 4문항: 양쪽 모두 추천 없음

MRR@5 1.00은 첫 관련 공고의 순위를 뜻합니다. 전체 서비스 정확도로 해석하지 않습니다.

관련 공고 회수 수준은 Recall@5 0.75입니다. 이후 모델 변경에 대한 신규 비교는 수행하지 않았습니다.

RAG 평가: 답변 상태와 조건 보존을 분리

모델·검색·칭킹을 고정하고, 답변의 대상 범위와 조건 관계를 보존하도록 프롬프트를 보완했습니다

보완 후 기대 답변 상태 일치

12/12

가상 6/6 + 공식 HTML 6/6

인용 경로·원문 연결

저장 캡처의 구조 검증 통과

자동 의미 충실도: 미측정

semanticFaithfulness = null

공식 H01: 대상 범위 누락 보완

대상 범위 일부 생략

→ **중소·중견 제조기업 범위 명시**

AI 원문 대조: 부분 일치 → 일치

프롬프트에서 보존할 조건

대상 범위 · 필수/우대/예외 구분

AND/OR 관계

공식 v1도 상태 일치는 6/6이었습니다. 의미 검토는 AI 판정이며 사람 검수는 남아 있습니다.

공식 공고 2개·각 1칭크의 저장 HTML 재생입니다. 다중 칭크 검색·PDF/HWP 품질은 평가하지 않았습니다.

응답 지연: 캐시와 Fast 효과를 각각 확인

반복 검색 2회와 랭킹 방식별 6회 실험입니다. 같은 성공 사례를 맞춰 지연을 비교합니다

동일 확인 검색 2회

첫 호출

42.467초

→

캐시 적중

0.484초

임베딩·랭킹 캐시 적중
AI Service 메모리 · TTL 300초

조건 해석 시간 제외
첫 응답의 지역 오추천도 재사용

일반 / Fast 랭킹

캐시 우회 · 고정 후보 20개 · 각 6회

	일반	Fast
성공/시도	4/6	6/6
공통 성공 4건 지연 중앙값	41.097초	28.617초

공통 성공 4건 기준 약 30.4% 단축

출력 축약 실험: 성공 3/6 · 중앙값 44.775초 → 미채택
순차 실행·소표본 결과입니다. 운영 p95·동시 부하·전체 채팅 대기시간과 의미 품질은 별도 평가합니다.

검증 결과를 코드·AI 품질·운영으로 구분

자동 테스트 통과와 소표본 품질 개선은 서로 다른 근거입니다

자동 테스트 · 빌드

Frontend: 테스트·lint·production build

Core: JDK 21 clean build·DB 통합

AI: pytest·잠금 의존성·패키지 빌드

실제 저장소 · 외부 응답 스텝

MySQL 8.4 Testcontainers로 SQL 검증

Compose에서 검색 엔진·큐 연결 확인

OpenAI 스텝 통과로 답변 품질을 보증하지 않음

검색 · RAG 품질 기록

고정 데이터·질문·후보의 전후 결과 비교

48·300문항 / 양성 2문항 / RAG 12문항

AI 참조 라벨·개발 진단: 사람 정답셋 필요

운영 검증의 남은 범위

단일 EC2: 고가용성·무중단 미보장

구버전 색인 정리·보안·부하·장애 복구 시험

기존 배포 기록 기준: 현재 AWS 상태 미재조회

검토 기준: 저장소 구성과 기존 배포·평가 기록. 이번 문서 개정에서 운영·유료 API 평가는 실행하지 않았습니다.

GOVBIZ · 다음 검증

근거를 확인하고, 실행 상태를 남기는 AI

검색 누락과 일부 답변 조건은 개선됐으며, 운영 품질은 추가 검증이 필요합니다.

01 사람 검수 정답셋

독립 검증 질문·합격선 사전 정의
무정답·자격 충돌·조건 누락 포함

02 검색·근거 재평가

현재 모델·다중 청크·PDF/HWP
Recall·인용·의미·실패율 측정

03 운영 품질 검증

동시 부하와 p50/p95·비용 측정
큐·DB·색인 장애 및 복구 시험

운영 성과와 실제 신청 자격은 별도의 검증으로 확인합니다.